


Intelligent Automotive Diagnostics

Diagnóstico OBD-II asistido por IA agéntica sobre el protocolo MCP

Jesús Ángel Novillo Lucas-Vaquero

Trabajo Fin de Máster · Máster en Desarrollo con IA · BIG school

LA HERRAMIENTA, EN FUNCIONAMIENTO



Lo que te da la máquina

Te da

- P0301 Fallo de encendido en el cilindro 1
- P0401 Válvula EGR obstruida
- P2002 Filtro de partículas lleno
- Y así hasta diez

No te da

- Por qué se ha obstruido la válvula
- Por qué se ha llenado el filtro
- Qué tiene que ver un código con otro
- Por dónde empezar a mirar

Lo que hace la aplicación

Con esos mismos códigos y los datos del coche.

- Investiga por qué puede estar pasando eso
- Le da al mecánico una serie de opciones, no una sola causa
- Y los pasos a seguir para determinar de dónde viene el problema

El sistema de un vistazo

Quién llama a quién. Todo lo de fuera entra por un puerto.



Las herramientas del agente vuelven a entrar por los mismos adaptadores: leen el coche y escriben en el catálogo.

Por qué esta arquitectura y no otra

Aquí el dominio son normas. Y las normas no las cambia nadie.

Por qué Clean + Hexagonal

- El dominio son normas: SAE J1979, ISO 15031, ISO 3779
- Las fórmulas de cada PID y la decodificación del VIN
- Nada de eso se mezcla con la base de datos ni con el LLM

En este proyecto

Dominio

Vin, DtcCode, PidCode, Formula, catálogos de PID y DTC

Aplicación

IdentifyVehicle, ExecuteCognitiveDiagnosis, ObdRepository, LlmClientPort

Infraestructura


Express, Drizzle + SQLite, LanceDB, servidor MCP, transporte ELM327

Por qué no orientada a eventos

- Es un proceso: no hay servicios que desacoplar
- El mecánico pregunta y espera: el flujo es síncrono
- Un solo programador: más piezas es más sitio donde romper

Cómo se lee el coche

Un ejemplo: pedirle las revoluciones del motor.



Va **01 0C** modo 01, PID 0C — revoluciones

Vuelve **41 0C 0B B8** los dos bytes de datos son A = 0B y B = B8

$$(A \times 256 + B) / 4 = (11 \times 256 + 184) / 4 = \mathbf{750 \text{ rpm}}$$

Dos bases de datos

En una se busca por clave. En la otra, por parecido.

SQLite

- Usuarios, talleres, vehículos, ECUs y sesiones
- Los catálogos de PID, DTC y ECU: los de la norma y los que se descubren
- Se consulta por clave: este VIN, este PID

LanceDB, vectorial

- Ese mismo conocimiento, indexado por significado
- Y los diagnósticos ya resueltos, que aquí no están
- Se consulta por parecido, no por clave
- El buscador de texto de SQLite no llega: «presión de aceite» no encuentra «oil pressure»

SQLite: el catálogo y los datos del taller

13 tablas. Todo lo que se puede pedir por una clave exacta.

Qué guarda

- Usuarios: particulares o talleres, con su rol
- Vehículos por VIN y las ECUs de cada uno
- Sesiones de diagnóstico, con el informe congelado
- Lecturas de PID: el hexadecimal crudo y el valor ya convertido
- Logs y auditoría de cada petición
- Y crece solo: un PID leído que no esté en el catálogo se inserta con confianza 0,3

Lo que viene sembrado al arrancar

- 20** PIDs de la norma SAE J1979
- 23** códigos DTC estándar
- 27** fabricantes, por su código WMI

Qué se guarda en la base vectorial

Los datos del taller van en SQLite. Aquí solo va lo que el sistema aprende.

Colecciones

- PIDs propietarios que no están en la norma, con su fórmula
- DTCs específicos de un fabricante
- Casos resueltos: síntomas, PIDs implicados y solución

Un caso resuelto, tal cual se guarda

embeddedText "Audi A3 2.0 TDI con P0401 y P2002: EGR obstruida por carbonilla de un motor que consume aceite"

symptoms ralentí inestable · pérdida de potencia

pidsInvolved 010C · 0105 · 22F40C

confidence 0,5 · manufacturer Audi · model A3

Índice de confianza

Se lo ponemos nosotros al guardar, según de dónde salga el dato. Es lo que pondera las búsquedas.

0,3 lo encontró el agente en internet

0,5 viene de un diagnóstico anterior

0,8 lo aportó el mecánico a mano

1,0 se ha leído del coche por OBD

Validar contra el coche sube la web a 0,7 y al mecánico a 0,9.

MCP: las herramientas del agente

El modelo no toca el coche. Pide una herramienta, y el sistema decide si se ejecuta.

Las 16 herramientas

Diagnóstico • 7

```
read_vin    read_pid    get_available_pids
get_dtc_codes  get_freeze_frame
get_vehicle_info  get_ecu_info
```

Conocimiento • 8

```
search_similar_pids  search_similar_dtcs
search_similar_diagnoses  search_similar_ecus
index_pid    index_dtc    index_diagnosis    index_ecu
```

Web • 1

```
web_search
```

Por qué MCP

- Es el estándar con el que un modelo pide herramientas, y solo sirve para eso
- El modelo solo actúa por ahí: no hay otra puerta al sistema
- Cada herramienta declara su esquema, y los argumentos se validan antes de ejecutarla
- El servidor vive en infraestructura: el modelo nunca ve el dominio
- Cambiar de modelo no toca las herramientas

Cómo razona el agente

Del botón de iniciar diagnóstico a la respuesta que lee el mecánico.

El ciclo

- 1 Al iniciar el diagnóstico se leen los PIDs generales, los DTCs y el freeze frame
- 2 Antes de llamar al modelo se buscan casos parecidos en la vectorial, y entran en el prompt
- 3 El modelo pide herramientas: mira el catálogo, lee más PIDs, busca lo que no conoce
- 4 Máximo 10 vueltas de ese ciclo, y 60 segundos de límite
- 5 Devuelve la explicación para el mecánico y un bloque JSON con severidad, confianza y recomendaciones
- 6 El caso resuelto se indexa con confianza 0,5, y la conversación sigue desde ahí

El prompt lleva 11 bloques

- Cómo explorar el coche y en qué orden
- Consultar el catálogo antes de inventarse nada
- Cómo aprender un PID, un DTC o una ECU nuevos
- Qué queda fuera de su ámbito y no debe contestar
- Que lo que llega de la web y del catálogo no es de fiar
- Cómo hablarle a un mecánico, y cómo rematar en JSON

Los dos modelos

Uno razona y se puede cambiar. El otro convierte texto en vectores y va dentro.

El modelo de lenguaje

- Una variable de entorno: LLM_PROVIDER = anthropic u openai
- Los dos clientes implementan el mismo puerto, LlmClientPort
- El adaptador de OpenAI sirve también para DeepSeek, Groq, Mistral o xAI
- Sin proveedor configurado, el diagnóstico determinista sigue funcionando

El modelo de embeddings

`paraphrase-multilingual-MiniLM-L12-v2`

- Corre en la propia máquina, con transformers.js
- Sin clave, sin red y sin coste por consulta
- Convierte cada texto en 384 números, normalizados
- Es multilingüe: por eso «presión de aceite» encuentra «oil pressure»

Dos diagnósticos

El determinista está siempre. El cognitivo, solo si hay un modelo configurado.

Determinista

- Lee cuatro PIDs fijos: revoluciones, refrigerante, velocidad y admisión
- Más los DTCs y el freeze frame
- La criticidad sale de una regla: sin DTCs es baja, con freeze frame es crítica
- Solo necesita el coche, y responde al momento
- No aprende nada


Cognitivo

- El agente decide qué PIDs le hace falta leer
- Razona sobre lo que va encontrando, llamando a herramientas
- Necesita el coche, la API del modelo y los índices vectoriales
- Hasta 60 segundos de límite
- Y aprende: indexa PIDs, DTCs y el caso resuelto


La aplicación funcionando

Audi A3 2.0 TDI. Todo lo que se ve viene leído del bus, nada está escrito a mano.


Lee el VIN del bus y saca marca, modelo y motor




Telemetría en vivo y los PIDs que soporta



Las averías: modos 03, 07 y 0A



El informe que se congela con la sesión



Con qué está hecho

TypeScript de punta a punta, y cada pieza detrás de un puerto.

Lenguaje y runtime

TypeScript 5.7 estricto sobre Node 22

API

Express 5 · Zod · Helmet 8 · JWT · pino

Persistencia

SQLite con Drizzle ORM

Búsqueda vectorial

LanceDB · transformers.js en local

Agente

MCP SDK · SDK de Anthropic · SDK de OpenAI

Acceso al coche

ELM327 por serie o TCP · emulador Python

Interfaz

React 19 · Vite · TanStack Router y Query · Tailwind

Pruebas

Vitest · supertest · Playwright

Entrega

GitHub Actions · Docker · Caddy

Cómo se sostiene esto

Un solo programador, así que el que avisa de las roturas es el CI.

Cómo se escribe

- TDD: primero el test que falla, luego el código
- 2.171 pruebas en verde, en 209 ficheros
- La cobertura se exige fichero a fichero, no de media
- 45 cambios especificados y archivados con OpenSpec

Qué se comprueba en cada push

- Lint, formato, tests, build y typecheck
- Las dos apps en paralelo, sobre Node 22
- Auditoría de dependencias que rompe si hay algo crítico
- OWASP API Top 10 2023: las diez categorías, documentadas

Conclusiones

Lo que me llevo de haber construido esto con IA.

Lo que acelera

- Se pueden construir cosas complejas mucho más rápido
- Lo que antes eran meses o años, ahora son semanas
- Y se aprende más por el camino: herramientas y frameworks que no habrías tocado

Lo que hay que poner

- Acelera, pero también se equivoca
- Hay que revisar lo que se sube, no vale con fiarse
- No es todo tan bonito como parece: hay que dedicarle tiempo

Gracias por la atención

Jesús Ángel Novillo Lucas-Vaquero

Máster en Desarrollo con IA · BIG school

EL INFORME DE LA SESIÓN

Intelligent Automotive Diagnostics
HERRAMIENTA OBD-II · DIAGNÓSTICO ASISTIDO POR IA

CONECTADO · 07:59:02 · Audi A3 2.0 TDI · Audi A3 · 2018 · VIN: WAUZZZ8V53A123456 · 25 de agosto de 2026

INFORME DE SESIÓN DE DIAGNÓSTICO

Audi A3
2018 · 2.0 TDI

DIAGNÓSTICO DETERMINISTA

CRÍTICO
[CRITICAL] P0301, P0401, P2002 (freeze frame: P0301 → Throttle Position, Calculated Engine Load, Engine Coolant Temperature, Engine RPM, Vehicle Speed)

CÓDIGO DTC (3)	DESCRIPCIÓN
P0301	Cylinder 1 Misfire Detected
P0401	Exhaust Gas Recirculation Flow Insufficient Detected
P2002	Diesel Particulate Filter Efficiency Below Threshold (Bank 1)